

Taller - Bases de Datos Vectoriales y Chunking Semántico

Este taller integra los conceptos y técnicas vistos en los cuatro notebooks desarrollados en clase sobre bases de datos vectoriales, embeddings y chunking. El objetivo es que el estudiante pueda aplicar estrategias de preprocesamiento, generar representaciones semánticas y comparar el impacto del chunking y la consulta en lenguaje natural en la recuperación de información.

Objetivo General

Desarrollar una solución de recuperación semántica sobre un conjunto de textos multitemáticos que permita explorar cómo las decisiones de segmentación afectan la precisión de los resultados.

Instrucciones Generales

- Trabaje directamente en los notebooks ya desarrollados o duplique los archivos si desea mantener la versión original.
- Utilice textos propios o extraídos de medios digitales (mínimo 500 palabras combinadas).
- Asegúrese de conservar al menos dos idiomas (español e inglés) y mezclar tipos de contenido (reseñas, descripciones, noticias, narraciones).

Actividades

1. 1. ****Preparación del Corpus****

Recoja o redacte un documento multitemático de al menos 500 palabras. Incluya títulos y fragmentos en diferentes idiomas y temáticas. Separe el contenido en un archivo `.txt`.

2. 2. ****Embeddings y Visualización****

Genere los embeddings para cada línea del texto o frase individual. Visualice la matriz de similitud y analice cuál(es) frases parecen más parecidas entre sí. Interprete los resultados con base en el significado.

3. 3. ****Chunking Semántico****

Implemente al menos dos métodos de segmentación (por número de oraciones y por ventana deslizante). Aplique los embeddings por chunk. Evalúe cuál de los dos métodos

preserva mejor la coherencia semántica. Justifique con ejemplos.

4. 4. ****Consulta en Lenguaje Natural****

Realice al menos 3 consultas semánticas sobre los chunks generados. Para cada consulta:

- Presente los chunks más similares y sus puntuaciones.
- Explique por qué fueron recuperados esos y no otros.
- Proporcione una interpretación del grado de similitud obtenido.

5. 5. ****Evaluación del Tamaño del Chunk****

Use el notebook 4 para evaluar cómo varía la precisión al modificar `max\_sentences` y `overlap`. Complete la tabla generada y argumente cuál sería la configuración óptima para textos largos, cortos y altamente temáticos.

6. 6. ****Conclusiones y Recomendaciones****

Elabore un breve informe (mínimo 300 palabras) con conclusiones sobre:

- La importancia del preprocesamiento para recuperación semántica.
- Recomendaciones sobre chunking para dominios reales (médico, turismo, tecnología, etc.).
- Posibles mejoras o aplicaciones futuras.

Entregables

- Archivos `.ipynb` modificados o nuevos con los experimentos.
- Archivos `.txt` de entrada utilizados.
- Documento PDF o Word con las respuestas interpretativas.

Criterios de Evaluación

- Implementación técnica completa y funcional.
- Argumentación clara y justificada.
- Originalidad del corpus y las consultas.
- Interpretación crítica de los resultados.
- Presentación organizada y completa.